



## ΣΤΑΤΙΣΤΙΚΗ ΣΤΗΝ ΠΛΗΡΟΦΟΡΙΚΗ

### ΑΚΑΔΗΜΑΪΚΟ ΕΤΟΣ 2020-2021

### 3<sup>ο</sup> ΣΕΤ ΑΣΚΗΣΕΩΝ

ΓΡΗΓΟΡΙΑΔΟΥ ΓΕΩΡΓΙΑ ,3160029

#### **ΑΣΚΗΣΗ 1 (α)**

Πραγματοποιούμε άπειρες ρίψεις και παίρνουμε δείγμα από αυτές με  $n = 50$  ρίψεις. Έστω  $X$  οι κορώνες και  $Y$  τα γράμματα με  $X = 29$  και  $Y = 21$ .

$X > 15$  και  $Y > 15$  άρα τα δεδομένα μας είναι κατάλληλα.

$$\hat{p} = \frac{X}{n} = \frac{29}{50} = 0.58, \sigma_{\hat{p}} = \sqrt{\frac{p(1-p)}{n}} = \sqrt{\frac{0.58 \cdot 0.42}{50}} = 0.069$$

Για διάστημα εμπιστοσύνης  $C=95\%$  έχουμε  $z^*=1.96$  οπότε το ζητούμενο διάστημα είναι  $\hat{p} \pm z_* \sigma_{\hat{p}} = [0.4431, 0.7168]$

#### **ΑΣΚΗΣΗ 1 (β)**

Δίπλευρος έλεγχος  $H_0 : p = 0.5$  , Αφού το ζάρι είναι δίκαιο άρα η συχνότητα εμφάνισης κορώνας είναι  $\frac{1}{2}$ .

$$\text{Στατικός έλεγχος } z = \frac{0.58 - 0.5}{\sqrt{\frac{0.5(1-0.5)}{50}}} = 1.1313 \text{ άρα } p\text{-value} = 2\Phi(-|z|) = 0.25. \text{ Το}$$

$p$ -value είναι μικρή τιμή άρα δε θα μπορούσαμε να απορρίψουμε την μηδενική υπόθεση με σιγουριά.

### **ΑΣΚΗΣΗ 1 (γ)**

$N \geq \frac{z_*^2}{4m^2} = \frac{1.96^2}{4 \cdot 0.01^2} = 9604$  Άρα θα έπρεπε να πραγματοποιήσει 9604 ρίψεις.

### **ΑΣΚΗΣΗ 2**

Το μέγεθος του δείγματος που χρησιμοποιείται για τις δημοσκοπήσεις είναι ανεξάρτητο από το μέγεθος του πληθυσμού, καθώς σύμφωνα με τον τύπο  $n \geq \frac{z_*^2}{4m^2}$  το πρώτο εξαρτάται μόνο από το περιθώριο λάθους  $m$  και το επίπεδο εμπιστοσύνης. Άρα και για τις δημοσκοπήσεις στις Η.Π.Α ο αριθμός των 1100 ατόμων είναι αρκετός.

### **ΑΣΚΗΣΗ 3 (α)**

Έστω  $p_1$  το ποσοστό των καπνιστών που είναι άνδρες και  $p_2$  που είναι γυναίκες.

Δίπλευρος έλεγχος  $H_0 : p_1 = p_2$

Έχουμε  $n_1 = 30$  το πλήθος των αντρών και  $n_2 = 30$  το πλήθος των γυναικών.

Επίσης  $\hat{p}_1 = 12/30 = 0.4$  το ποσοστό των αντρών που καπνίζουν και  $\hat{p}_2 = 14/30 = 0.46$  το ποσοστό των γυναικών που καπνίζουν. Επίσης  $\hat{p} = \frac{12+14}{60} = 0.43$

Στατιστικός έλεγχος  $z = \frac{0.4-0.46}{\sqrt{\frac{0.43(1-0.4)}{30} + \frac{0.43(1-0.46)}{30}}} = -0.521$

Άρα το  $p$ -value = 0.60 το οποίο είναι αρκετά μεγάλο οπότε δε μπορούμε να απορρίψουμε τη μηδενική υπόθεση. Αυτό σημαίνει ότι υπάρχει σχέση μεταξύ φύλου και καπνίσματος.

### **ΑΣΚΗΣΗ 3 (β)**

Το ζητούμενο διάστημα εμπιστοσύνης είναι :

$$\widehat{p}_1 - \widehat{p}_2 \pm z^* \sqrt{\frac{\widehat{p}_1(1-\widehat{p}_1)}{n_1} + \frac{\widehat{p}_2(1-\widehat{p}_2)}{n_2}} = 0.4 - 0.46 \pm 1.96 \sqrt{\frac{0.4(1-0.4)}{30} + \frac{0.46(1-0.46)}{30}} =$$

[-0.194,0.061]

### **ΑΣΚΗΣΗ 3 (γ)**

Έστω ο έλεγχος  $H_0$  : Το φύλο δεν έχει σχέση με το κάπνισμα

$H_a$  : Το φύλο έχει σχέση με το κάπνισμα

#### **ΠΙΝΑΚΑΣ ΣΥΝΑΦΕΙΑΣ**

ΦΥΛΟ	ΚΑΠΝΙΣΤΗΣ	ΜΗ ΚΑΠΝΙΣΤΗΣ	
ΑΝΤΡΕΣ	12	18	30
ΓΥΝΑΙΚΕΣ	14	16	30
	26	34	60

### **ΑΣΚΗΣΗ 3 (δ)**

ΦΥΛΟ	ΚΑΠΝΙΣΤΗΣ	ΜΗ ΚΑΠΝΙΣΤΗΣ	
ΑΝΤΡΕΣ	13	17	30
ΓΥΝΑΙΚΕΣ	13	17	30
	26	34	60

$$\text{Στατιστικός έλεγχος } \chi^2 = \frac{(12-13)^2}{13} + \frac{(18-17)^2}{17} + \frac{(14-13)^2}{13} + \frac{(16-17)^2}{17} \approx 0.07$$
$$+0.058 + 0.07 + 0.058 \approx 0.256$$

#### **ΑΣΚΗΣΗ 4 (α)**

Θέλουμε να μάθουμε αν παρασκευάζονται περισσότερα κόκκινα smarties από ότι μπλε, άρα μας ενδιαφέρει ο υποπληθυσμός των κόκκινων και μπλε smarties. Έστω  $p$  το ποσοστό των κόκκινων και  $1-p$  των μπλε κουφέτων.

Ενδιαφερόμαστε να μάθουμε αν τα κόκκινα smarties είναι περισσότερα οπότε θα πάρουμε μονόπλευρο έλεγχο υπόθεσης  $H_0: p = \frac{1}{2}$ ,  $H_a: p > \frac{1}{2}$ .

Από τα δεδομένα της εκφώνησης έχουμε ότι:

$$n = 19 + 15 = 34, X = 19 \text{ και } \hat{p} = \frac{X}{n} = \frac{19}{34} = 0.5588.$$

Θεωρούμε ότι η συσκευασία αποτελεί ένα τυχαίο δείγμα με τα smarties που φτιάχνονται, δηλαδή ότι ο τρόπος με τον οποίο αναμιγνύονται τα χρώματα είναι τυχαίος.

$$\text{Ο στατιστικός έλεγχος είναι } z = \frac{\hat{p} - 0.5}{\sqrt{\frac{0.5(1-0.5)}{n}}} = 0.686 \text{ και το } p\text{-value} = 2\Phi(-|z|) = 0.4902.$$

Αφού η τιμή του  $p$ -value δεν είναι πολύ μικρή, η μηδενική υπόθεση είναι αποδεκτή.

Άρα, δεν υπάρχει σημαντική διαφορά στον αριθμό των κόκκινων και μπλε κουφέτων.

#### **ΑΣΚΗΣΗ 4 (β)**

Θέλουμε να δούμε αν η κατανομή των χρωμάτων είναι η ίδια σε σχέση με αυτή του 2009.

Θα εφαρμόσουμε τον  $\chi^2$  έλεγχο καλής προσαρμογής:

$H_0$ : η κατανομή των χρωμάτων καφέ, κόκκινο, κίτρινο, μπλε και πράσινο είναι 19.8%, 17.8%, 17.6%, 19.6% και 25.2% αντίστοιχα,

$H_a$ : η κατανομή των χρωμάτων είναι διαφορετική.

Από τα δεδομένα προκύπτει ο ακόλουθος πίνακας:

	Δεδομένα	Αναμενόμενες Τιμές
Καφέ	22	15.84
Κόκκινο	19	14.24
Κίτρινο	16	14.08
Μπλέ	15	15.68
Πράσινο	8	20.16

Με τη βοήθεια της R βρίσκουμε ότι  $p\text{-value} = 0.02$ , το οποίο είναι αρκετά μικρό για να ισχύει η μηδενική υπόθεση. Άρα η κατανομή των χρωμάτων είναι διαφορετική σε σχέση με το 2009.

#### **ΑΣΚΗΣΗ 4 (γ)**

Θα θεωρήσουμε ότι η συσκευασία των M&Ms αποτελεί ένα τυχαίο δείγμα από τον πληθυσμό των κουφέτων της συγκεκριμένης μάρκας. Θα ελέγξουμε αν τα δείγματα των smarties και των M&Ms προήλθαν από πληθυσμούς με την ίδια κατανομή χρωμάτων. Για αυτό τον έλεγχο θα χρησιμοποιήσουμε έναν  $\chi^2$  έλεγχο για ομοιογένεια.

$H_0$ : οι πληθυσμοί των smarties και των M&Ms είναι ομοιογενείς.

$H_a$ : οι πληθυσμοί δεν είναι ομοιογενείς.

Από τα δεδομένα προκύπτει ο ακόλουθος πίνακας συνάφειας:

	smarties	M&Ms	
Καφέ	22	10	32
Κόκκινο	19	12	31
Κίτρινο	16	20	36
Μπλέ	15	9	24
Πράσινο	8	5	13
	80	56	136

Με τη βοήθεια της R βρίσκουμε ότι ο στατιστικός έλεγχος είναι  $\chi^2 = 4.626$ , οι βαθμοί ελευθερίας = 4 και  $p\text{-value} = 0.3278$ .

Το  $p\text{-value}$  είναι αρκετά μεγάλο ώστε να μην απορριφθεί η μηδενική υπόθεση, οπότε οι κατανομές των χρωμάτων στα smarties και τα M&Ms είναι ίδιες.